

Higor Henrique Garcia

RM: 571820

Fase 1 - Capítulo 2
IA e seu mundo de possibilidades

Relatório de Estudo de Caso
Classificação de Utensílios de Cozinha
com Teachable Machine (Google)

FIAP - Março 2026

1. Objetivos

Este trabalho teve como objetivos: (i) desenvolver um modelo de visão computacional capaz de classificar fotografias de utensílios de cozinha em categorias pré-definidas; (ii) aplicar conceitos básicos de aprendizado de máquina supervisionado; (iii) utilizar a ferramenta Teachable Machine para treinar e validar o modelo sem necessidade de código; e (iv) avaliar o desempenho do modelo por meio de testes com imagens não utilizadas no treinamento, comparando diferentes configurações de hiperparâmetros.

2. Metodologia

2.1 Coleta e organização dos dados

Foram definidas três classes de utensílios de cozinha: Panelas, Talheres e Utensílios de Preparo. As imagens foram obtidas por meio de fotografias realizadas em ambiente doméstico, utilizando um smartphone Samsung Galaxy S24 Ultra. As fotos foram tiradas com boa iluminação, foco nítido no objeto e fundo neutro (bancada de granito escuro), evitando elementos que pudessem interferir na detecção.

O conjunto de dados foi organizado da seguinte forma:

- Panelas: 21 imagens (panelas e frigideiras em diferentes ângulos)
- Talheres: 42 imagens (garfos, facas e colheres em variações de modelo)
- Utensílios de Preparo: 21 imagens (espátulas, conchas, colheres de pau)

De cada classe, foram reservadas imagens para o conjunto de teste, garantindo que não fossem utilizadas durante o treinamento.

2.2 Ferramenta e configuração do modelo

Utilizou-se o Teachable Machine (Google), acessível em <https://teachablemachine.withgoogle.com>, selecionando a opção 'Image Project' com 'Standard image model'. As imagens de treino foram carregadas por classe. Foram realizados dois experimentos com configurações avançadas distintas:

Experimento	Epochs	Batch Size	Learning Rate	Observação
1 (baseline)	50	16	0,001	Padrão da ferramenta
2 (ajuste)	100	16	0,001	Dobro de épocas

>>> Print 1: Tela do Teachable Machine com as 3 classes e amostras de imagens carregadas <<<

3. Desenvolvimento do Experimento

O desenvolvimento seguiu as seguintes etapas:

1. Criação do projeto no Teachable Machine e definição das três classes com nomes descritivos: Panelas, Talheres e Utensílios_de_Preparo.

2. Upload das imagens de treinamento em cada classe. A classe Talheres recebeu um volume maior de imagens (42) por conta da maior variedade de objetos nessa categoria (garfos, facas de diferentes tamanhos, colheres de sopa e de chá). As classes Panelas e Utensílios de Preparo

receberam 21 imagens cada.

3. Primeiro treinamento (Experimento 1) com os parâmetros padrão: 50 epochs, batch size 16, learning rate 0,001. A ferramenta processou as imagens e gerou um modelo de classificação baseado em transfer learning.

4. Teste rápido do Experimento 1 utilizando a webcam, apresentando uma faca à câmera para verificar se o modelo respondia corretamente.

5. Segundo treinamento (Experimento 2) com o dobro de épocas (100), mantendo batch size e learning rate idênticos, para observar o efeito na precisão.

6. Teste completo do Experimento 2, apresentando três objetos diferentes (colher de pau, frigideira e faca) à webcam, um por vez.

>>> Print 2: Configurações avançadas do treinamento (Epochs, Batch Size, Learning Rate) <<<

4. Testes e Avaliação

4.1 Resultados do Experimento 1 (50 epochs)

Após o primeiro treinamento, foi realizado um teste rápido apresentando uma faca à webcam. O modelo classificou corretamente como Talheres com confiança de 96%.

>>> Print 3: Teste do Experimento 1 - Faca classificada como Talheres (96%) <<<

4.2 Resultados do Experimento 2 (100 epochs)

Após o segundo treinamento com o dobro de épocas, foram testados três objetos distintos via webcam:

Objeto testado	Classificação	Confiança	Acertou?
Colher de pau	Utens. de Preparo	100%	Sim
Frigideira	Panelas	100%	Sim
Faca	Talheres	94%	Sim

>>> Print 4: Teste Experimento 2 - Colher de pau classificada como Utensílios (100%) <<<

>>> Print 5: Teste Experimento 2 - Frigideira classificada como Panelas (100%) <<<

>>> Print 6: Teste Experimento 2 - Faca classificada como Talheres (94%) <<<

4.3 Comparação entre experimentos

Para o mesmo objeto (faca), os resultados foram:

- Experimento 1 (50 epochs): Talheres com 96% de confiança
- Experimento 2 (100 epochs): Talheres com 94% de confiança

Ambos classificaram corretamente, porém o Experimento 1 apresentou confiança ligeiramente superior (96% vs. 94%). Essa diferença, embora pequena, pode indicar um princípio de overfitting no Experimento 2: com mais épocas, o modelo se especializou demais nas imagens de treinamento, perdendo uma fração de capacidade de generalização para imagens novas.

5. Justificativa Técnica dos Resultados

O desempenho elevado do modelo pode ser explicado pelos seguintes fatores:

1. Qualidade e consistência dos dados: as imagens foram fotografadas no mesmo ambiente, com iluminação e fundo consistentes, facilitando a extração de características relevantes do objeto pelo modelo.
2. Diferenciação visual entre classes: panelas possuem forma arredondada e tamanho grande; talheres são alongados e metálicos; utensílios de preparo variam entre madeira e silicone. Essa distinção visual reduz a confusão.

3. Volume adequado de dados: com 21 a 42 imagens por classe e variação de ângulo, o modelo conseguiu generalizar para objetos apresentados ao vivo.

4. Hiperparâmetros: 50 epochs foram suficientes para convergência dada a simplicidade do problema (3 classes visualmente distintas). O aumento para 100 epochs não trouxe melhoria, confirmando que o modelo já havia convergido.

5. A pequena queda de confiança da faca (96% para 94%) ao dobrar epochs reforça o conceito de que mais treinamento nem sempre é melhor - o equilíbrio entre underfitting e overfitting é fundamental em aprendizado de máquina.

6. Análise Crítica e Sugestões de Melhoria

Limitações identificadas neste estudo:

- Conjunto de dados reduzido: embora suficiente para três classes distintas, um cenário com mais categorias ou objetos visualmente similares exigiria conjuntos maiores (50+ imagens por classe).
- Ambiente controlado: o modelo foi treinado com imagens de um único ambiente. Em cenários reais com iluminação variável, fundos diferentes ou múltiplos objetos na cena, o desempenho poderia ser inferior.
- Desbalanceamento de classes: a classe Talheres (42 imagens) teve o dobro das demais (21 cada), o que pode introduzir viés a favor dessa classe.
- Teste limitado: apenas 3 objetos foram testados por classe. Uma avaliação estatisticamente robusta exigiria um conjunto de teste maior.

Sugestões de melhoria:

- Aumentar o número de imagens por classe com variação de fundo, iluminação e distância.
- Balancear as classes para evitar viés.
- Incluir uma classe 'Outros' para evitar classificações forçadas.
- Exportar o modelo e avaliá-lo com métricas de precisão, revocação e F1-score.
- Testar com imagens de outros dispositivos e ambientes para validar generalização.

7. Conclusão

O Teachable Machine permitiu construir um classificador de imagens de forma rápida e acessível, cumprindo os objetivos de familiarização com aprendizado de máquina e visão computacional. Os resultados foram satisfatórios, com acurácia de 100% nos testes e confiança entre 94% e 100%. A comparação entre os dois experimentos evidenciou que o aumento de épocas não trouxe melhoria significativa, e até reduziu levemente a confiança em um dos casos, reforçando a importância do ajuste adequado de hiperparâmetros. As oportunidades de melhoria identificadas servem como direcionamento para projetos futuros com maior complexidade e robustez.

Referências

Google. Teachable Machine. Disponível em: <https://teachablemachine.withgoogle.com>. Acesso em: 24 mar. 2026.